

Estimation de la fréquence cardiaque par rPPG robuste aux carnations foncées

Comparaison de méthodes classiques et profondes, fine-tuning de PhysNet,
approche par régions + CNN 1D, et pistes d'amélioration

Projet mp-rppg-eval

25 juin 2026

Résumé

Ce rapport synthétise nos travaux sur l'estimation sans contact de la fréquence cardiaque (FC) à partir d'une vidéo du visage (*remote photoplethysmography*, rPPG), avec un objectif central : la robustesse sur les **carnations foncées** (Fitzpatrick 4–6), là où la littérature et les solutions commerciales restent fragiles. Nous comparons deux familles d'approches — les méthodes de *démixage chromatique* (CHROM, POS) et les réseaux profonds spatio-temporels (PhysNet) — et nous introduisons deux approches conçues pour la robustesse inter-carnation : (i) un **CNN 1D** appliqué à des signaux multi-régions / multi-espaces colorimétriques extraits par segmentation faciale profonde (BiSeNet), et (ii) **CHROM-ITA**, une variante de CHROM dont les coefficients de projection sont conditionnés par l'angle typologique individuel (ITA) de la peau. Nous décrivons la motivation théorique de chaque choix, le protocole expérimental (évaluation au *niveau scénario* et politique de confiance fondée sur le rapport signal/bruit, SNR), les résultats obtenus sur le jeu VitalVideos (**DataVital**), et un ensemble de pistes à explorer — notamment la **fusion par sélection SNR**, l'ajout d'un canal **ballistocardiographique** (BCG) indépendant de la couleur de peau, et une architecture de décision multi-signal inspirée de Binah.AI.

Table des matières

1	Contexte et objectif	2
2	Méthodes comparées	2
2.1	Démixage chromatique : CHROM et POS	2
2.2	Réseau profond spatio-temporel : PhysNet	3
2.3	Approche par régions + CNN 1D	3
2.4	CHROM-ITA : démixage conditionné par la carnation	3
2.5	Repères industriels : Binah.AI	4
3	Protocole expérimental	4
3.1	Audit du prétraitement (avant ré-entraînement)	4
3.2	Évaluation au niveau scénario (et non par fenêtre)	4
3.3	Politique de confiance fondée sur le SNR	4
4	Résultats	5
4.1	Choix de la base PhysNet à fine-tuner	5
4.2	Stratégie de fine-tuning : geler ou non ?	5
4.3	Comparaison des méthodes (niveau scénario, base propre)	5
4.4	Test sur 2 vidéos externes (carnations très foncées)	6
4.5	Bilan terrain : 5 vidéos externes, tout le spectre de carnations	7
4.6	Test <i>held-out</i> sur 22 sujets jamais vus (majorité Fitz 5–6)	7

5	Discussion	8
6	Pistes à explorer	9
7	Conclusion	9

1 Contexte et objectif

La photopléthysmographie à distance (rPPG) exploite les minuscules variations de couleur de la peau induites, à chaque battement cardiaque, par la variation du volume sanguin dans le lit capillaire sous-cutané [1, 2]. Une caméra RGB ordinaire suffit en principe à reconstruire un signal pulsatile et à en déduire la FC.

Le problème des carnations foncées. L’amplitude du signal rPPG est proportionnelle à la lumière *rétrodiffusée* après avoir traversé l’épiderme. Or la mélanine, concentrée dans l’épiderme, absorbe fortement dans le visible (surtout aux courtes longueurs d’onde). Sur une peau Fitzpatrick 5–6, le rapport signal/bruit (SNR) du signal pulsatile chute donc mécaniquement, et toutes les méthodes optiques se dégradent [13, 14]. C’est un enjeu d’équité : plusieurs solutions grand public sous-performent sur les peaux foncées. Notre objectif est de **quantifier** cette dégradation sur nos méthodes et de la **réduire**.

Jeu de données. Nous travaillons sur des vidéos au format *VitalVideos* [15] (dossier *DataVital*) : chaque sujet est filmé en plusieurs *scénarios* (~ 20 s, 30–60 fps), avec une vérité-terrain PPG synchronisée (oxymètre de doigt) et des métadonnées (âge, sexe, **phototype Fitzpatrick**, environnement). *VitalVideos* est précisément conçu pour couvrir une diversité de carnations, ce qui en fait un banc d’essai pertinent. À ce jour ~ 89 sujets sont prétraités et exploités pour l’entraînement ; un lot supplémentaire de 22 sujets jamais vus sert de test *held-out*.

2 Méthodes comparées

2.1 Démixage chromatique : CHROM et POS

Ces méthodes *non supervisées* partent d’un modèle de réflectance de la peau. On extrait la couleur moyenne RGB d’une région de peau au cours du temps, on la normalise, puis on projette les trois canaux sur une direction où la pulsation est maximisée et l’artéfact de mouvement (variation d’intensité spéculaire) annulé.

- **CHROM** [3] construit deux signaux chrominance $X = 3R_n - 2G_n$ et $Y = 1.5R_n + G_n - 1.5B_n$ (coefficients issus d’une hypothèse de teinte de peau *standardisée*), puis combine $S = X - \alpha Y$ avec α égalisant les écarts-types. C’est la méthode de référence, robuste et rapide.
- **POS** (*Plane-Orthogonal-to-Skin*) [4] définit un plan orthogonal à la direction moyenne de la peau dans l’espace RGB temporel et y projette le signal. Théoriquement mieux fondée que CHROM sur le plan du modèle de réflectance, souvent plus robuste au mouvement.

Limite pour notre problème. Les coefficients de CHROM/POS sont *figés* et calibrés implicitement sur une teinte de peau $\bar{n}$ moyenne $\bar{z}$. Sur une carnation très foncée (faible signal, spectre de réflectance déplacé), cette projection fixe n’est plus optimale — c’est la motivation directe de CHROM-ITA (§2.4).

2.2 Réseau profond spatio-temporel : PhysNet

PhysNet [5] est un encodeur-décodeur *3D-CNN* : il prend en entrée un cube spatio-temporel (typiquement 128 images $\times 72 \times 72$ pixels du visage) et régresse directement la forme d'onde rPPG, image par image. Les convolutions 3D capturent conjointement la texture spatiale et la dynamique temporelle, ce qui permet en principe d'apprendre des indices que CHROM/POS ignorent (micro-textures, distribution spatiale de la pulsation).

Prétraitement *DiffNormalized*. Comme dans la lignée DeepPhys/MTTS-CAN [6, 7], l'entrée est la différence normalisée entre images consécutives, qui accentue les variations pulsatiles et atténue l'éclairage statique. *Revers de la médaille* : sur une vidéo smartphone fortement compressée (H.264), cette différence amplifie les artéfacts de compression temporelle — une limite que nous avons observée et documentée.

Pourquoi fine-tuner. Les poids publics de PhysNet sont entraînés sur des jeux à dominante de peaux claires (SCAMPS synthétique, UBFC, PURE). Un fine-tuning sur des données diversifiées (VitalVideos) vise à recalibrer le réseau pour les carnations sous-représentées.

2.3 Approche par régions + CNN 1D

Idée (proche de la famille *MSTmap*/RhythmNet [8, 9]) : plutôt qu'un 3D-CNN coûteux sur des pixels bruts, on **réduit** d'abord la vidéo à un petit ensemble de *signaux 1D* robustes, puis on les traite par un réseau léger.

1. **Segmentation faciale profonde** par **BiSeNet** [10] (*face parsing*) : on isole précisément la peau et on découpe le visage en **23 régions** (7 régions anatomiques — front, joues, nez, menton... — + une grille 4×4).
2. Pour chaque région et chaque image, on calcule la couleur moyenne dans **9 canaux** couvrant 3 espaces colorimétriques (RGB, YUV, Lab), soit $23 \times 9 = 207$ signaux temporels.
3. Un **CNN 1D** dilaté (~ 113 k paramètres, dilations 1, 2, 4, 8) régresse la forme d'onde rPPG à partir de ces 207 canaux.

Justification. (i) La segmentation profonde garantit qu'on n'agrège que des pixels de peau (vs une boîte rectangulaire qui inclut cheveux, fond, vêtements) ; (ii) la *redondance* multi-régions / multi-espaces donne au réseau des combinaisons linéaires riches pour isoler la pulsation du bruit, *y compris* des combinaisons mieux adaptées à une carnation donnée — ce qu'un CHROM à coefficients fixes ne peut pas faire ; (iii) le modèle est minuscule et rapide, donc déployable.

Risque identifié : avec 207 canaux et peu de sujets, le sur-apprentissage guette (cf. §4).

2.4 CHROM-ITA : démixage conditionné par la carnation

Pour lever la rigidité de CHROM tout en gardant son interprétabilité, nous conditionnons ses coefficients sur la **carnation mesurée**. L'**ITA** (*Individual Typology Angle*) [12] est un descripteur continu de teinte de peau dérivé de l'espace $L^*a^*b^*$:

$$\text{ITA} = \arctan\left(\frac{L^* - 50}{b^*}\right) \cdot \frac{180}{\pi},$$

positif pour les peaux claires, négatif pour les peaux foncées. Un petit MLP ($1 \rightarrow 8 \rightarrow 5$) prend l'ITA de la région et produit les coefficients de projection chromatique, **initialisés sur les valeurs de De Haan** (de sorte que le modèle non entraîné $\equiv$ CHROM standard). On apprend ainsi une *famille continue* de démixages indexée par la carnation.

2.5 Repères industriels : Binah.AI

Binah.AI revendique une mesure multi-constantes (FC, VFC, SpO₂, respiration, stress) robuste à toutes les carnations, depuis une simple caméra. D’après leurs communications, leur pipeline repose sur : (i) le **TOI** (*Transdermal Optical Imaging*), c.-à-d. la même famille n couleur z que CHROM/POS; (ii) un module appris de **qualité de signal (SQA)** qui **rejette** les fenêtres trop bruitées et ne renvoie une mesure que lorsqu’elle est jugée fiable (d’où le fameux n measuring... z qui se prolonge en conditions difficiles); (iii) de *très gros* jeux d’entraînement multi-ethniques pour calibrer la conversion signal $\rightarrow$ constante vitale. **Enseignement pour nous** : leur avantage n’est pas un algorithme unique n anti-mélanine z, mais une **architecture de décision** (multi-signal + rejet par qualité). Nos briques SNR (§3.3) vont exactement dans ce sens.

3 Protocole expérimental

3.1 Audit du prétraitement (avant ré-entraînement)

Avant tout entraînement n propre z à grande échelle, nous avons audité la chaîne et corrigé trois défauts qui faussaient les résultats :

- **Augmentation temporelle de PhysNet** : le retournement temporel de l’entrée n’inversait pas la cible $y \Rightarrow$ paires (entrée, label) désalignées (corruption de label). *Corrigé* : x et y retournés conjointement.
- **Double filtrage passe-bande** dans le pipeline CNN 1D (label déjà filtré à l’extraction, puis re-filtré à l’entraînement). *Corrigé*.
- **Fréquences d’images hétérogènes** (40/60 fps à l’entraînement, ~ 30 fps au déploiement). *Corrigé* : ré-échantillonnage de toutes les séquences à **30 fps** (image la plus proche) pour homogénéiser la dynamique temporelle apprise.

La détection/suivi du visage a par ailleurs été basculée de Haar Cascade vers **MediaPipe FaceMesh** en mode *tracking* (landmarks propagés d’image en image), plus stable et évitant qu’une main (geste n facepalm z) soit prise pour le visage — les régions de peau étant de toute façon resegmentées par BiSeNet.

3.2 Évaluation au niveau scénario (et non par fenêtre)

Une erreur méthodologique fréquente consiste à mesurer la FC sur des fenêtres courtes (128 images ≈ 2 s) et à moyennner. Sur 2 s, la résolution fréquentielle de la FFT est grossière et la FC estimée est instable. Nous reconstruisons donc le signal **complet du scénario** (~ 20 s) puis estimons **une** FC par FFT. Cela change radicalement les chiffres (p. ex. une MAE PhysNet passant de $\sim 19,8$ par fenêtre à $\sim 7-8$ au niveau scénario) et constitue la seule comparaison équitable entre méthodes.

3.3 Politique de confiance fondée sur le SNR

Plutôt que de toujours renvoyer une FC, nous calculons pour chaque estimation un **SNR aveugle** : énergie spectrale dans une bande étroite autour du pic FC estimé, rapportée à l’énergie hors-bande dans $[0,7, 2,5]$ Hz. Nous appliquons alors la politique (inspirée du SQA de Binah, §2.5) :

$\text{SNR} > -1 \Rightarrow \text{VALID}$	$-3 \leq \text{SNR} \leq -1 \Rightarrow \text{douteux}$	$\text{SNR} < -3 \Rightarrow \text{REJET}$
--	---	--

Empiriquement, les échecs se concentrent vers ~ -3 dB et les succès vers $\sim +1,5$ dB : le SNR est donc un *signal de confiance* exploitable. *Réserve importante* : il n’est pas infaillible (cf. CHROM-ITA, §4).

4 Résultats

4.1 Choix de la base PhysNet à fine-tuner

Nous avons évalué les **5 jeux de poids publics** (SCAMPS, UBFC, PURE, MA-UBFC, BP4D) sur nos données. **PURE** généralise le mieux et a été retenu comme base. (SCAMPS, purement synthétique, marche bien sur UBFC mais mal sur nos vidéos; UBFC seul généralise encore moins.)

4.2 Stratégie de fine-tuning : geler ou non ?

Nous avons comparé quatre stratégies de gel sur la base PURE :

Variante	Couches entraînées	Résultat
A	tout le réseau (full fine-tune)	meilleure
B	gel ConvBlock4–9 + upsampling	moins bon
C	B + recalibration BatchNorm	moins bon
D	gel du seul goulot (ConvBlock8–9)	moins bon

Conclusion : le **full fine-tune (A)** domine. Le gel partiel crée un *goulot de capacité* — le réseau n’a pas assez de degrés de liberté pour se recalibrer sur la nouvelle distribution de carnations. On en retient aussi qu’il est normal qu’une perte par *corrélation de Pearson* (négative) ne s’étende pas vers 0 : elle est bornée par le bruit intrinsèque de la vérité-terrain ; une bonne corrélation peut coexister avec une MAE encore élevée, les deux mesurant des choses différentes.

4.3 Comparaison des méthodes (niveau scénario, base propre)

Sur le découpage de test (graine 42, 89 sujets, 20 scénarios de test), au niveau scénario, avec la politique SNR :

TABLE 1 – Comparaison globale. $\checkmark$ Validés $\hat{z}$ = scénarios avec $\text{SNR} > -1$; $\hat{z}$ MAE val. $\hat{z}$ = MAE sur ces seuls scénarios.

Méthode	MAE (bpm)	médiane	% < 5 bpm	Validés ($\text{SNR} > -1$)	MAE val.
CNN 1D	6,77	0,0	70 %	—	—
PhysNet	7,03	2,64	65 %	7/20	5,27
POS	—	—	—	9/20	0,39
CHROM-ITA	11,43	—	—	—	~26 (cas piégeux)

Lectures clés.

- **Au global**, CNN 1D (6,77) et PhysNet (7,03) sont au coude-à-coude (chiffres du découpage interne ; les modèles appris ont depuis été ré-entraînés sur données propres, cf. §4.6 pour les scores held-out de référence).
- **Sous la politique SNR**, **POS** domine nettement : 9/20 scénarios validés à **MAE 0,39**. Il est *conservateur mais fiable*.
- Le SNR de **PhysNet** est **honnête** : il *rejette* quand il échoue (p. ex. erreur de 28 bpm $\rightarrow$ SNR $-4,8 \rightarrow$ rejeté). Ses 7 scénarios validés sont propres (MAE 5,27).
- **CHROM-ITA** est le **seul danger** : il peut être *confiant et faux* (doublage d’harmonique : il verrouille sur $2 \times \text{FC}$ avec un SNR élevé). Le SNR seul ne suffit pas à le sécuriser $\Rightarrow$ garde anti-harmonique nécessaire (§6).
- Les échecs s’y peaufinent $\hat{z}$ sont des **cas individuels difficiles** (quelques sujets), pas une dégradation uniforme de toute la classe Fitzpatrick 6.

4.4 Test sur 2 vidéos externes (carnations très foncées)

Deux vidéos personnelles avec FC de référence mesurée par appareil externe, sur peaux très foncées ($ITA \leq -56$). C'est un test *in vivo* hors du jeu d'entraînement.

TABLE 2 – Vidéo A — réf. **54 bpm**, $ITA \approx -56$.

Méthode	FC estimée	erreur	SNR aveugle
CNN 1D	51,0	3,0	-0,26
PhysNet	80,9	26,9	-1,28
CHROM-ITA	64,2	10,2	-3,36
CHROM	63,3	9,3	-3,50
POS	96,7	42,7	-7,90
écart-type des FC	15,9 bpm (méthodes <i>divergentes</i>)		

TABLE 3 – Vidéo B — réf. **56 bpm**, $ITA \approx -65$.

Méthode	FC estimée	erreur	SNR aveugle
CNN 1D	49,2	6,8	-0,47
POS	56,2	0,2	-2,20
CHROM	56,2	0,2	-4,30
PhysNet	66,1	10,1	-3,64
CHROM-ITA	80,2	24,2	-5,28
écart-type des FC	10,8 bpm (méthodes <i>regroupées</i>)		

Deux régimes opposés — et c'est l'enseignement central.

- **Vidéo A (divergence).** Les méthodes sont éparpillées ; la moyenne naïve (75,6 bpm) est polluée par les fausses. Seule la *sélection par SNR* (CNN 1D, meilleur SNR) donne la bonne réponse (err 3).
- **Vidéo B (accord).** CHROM/POS retrouvent la FC *exacte* (56,2 vs 56) mais avec un SNR *faible* (signal tenu sur peau Fitz 6) : le SNR *sous-note* les bonnes méthodes. Ici la sélection-SNR retiendrait CNN 1D (err 6,8), tandis que la **médiane** des méthodes donne 56,2 (err 0,2).

Conséquence : une fusion ADAPTATIVE. Aucune règle fixe (moyenne seule, ou SNR seul) ne réussit sur les deux vidéos. Nous adoptons donc une fusion qui *bascule selon l'accord inter-méthodes* :

écart-type des FC $\leq \tau \Rightarrow$ consensus (médiane)	écart-type $> \tau \Rightarrow$ sélection (meilleur SNR validé)
--	--

avec $\tau \approx 12$ bpm et une *garde anti-harmonique* (on écarte un candidat dont la FC vaut $\approx 2 \times$ la médiane des autres). Résultats de cette fusion adaptative :

Vidéo	réf.	mode déclenché	FC fusionnée	erreur
A	54	sélection ($\rightarrow$ CNN 1D)	51,0	3,0
B	56	consensus ($\rightarrow$ médiane)	56,2	0,2

Cette stratégie est désormais la **méthode de fusion par défaut** du pipeline (`mp_rppg/fusion.py`, utilisée par `run_on_video.py`).

4.5 Bilan terrain : 5 vidéos externes, tout le spectre de carnations

En agrégeant toutes les vidéos personnelles testées avec le pipeline corrigé (modèles ré-entraînés sur données propres, fusion adaptative, CNN 1D ré-inclus), on couvre un large spectre d’ITA, du clair (+3) au très foncé (−65). Une de ces vidéos (IMG_9008) a été traitée en **test à l’aveugle** (réf. révélée *après* la prédiction).

TABLE 4 – Erreur de la **fusion adaptative** sur les vidéos externes. $\hat{z}$ mode $\hat{z}$ = branche déclenchée. ($\dagger$ = test à l’aveugle.)

Vidéo	réf. (bpm)	ITA	carnation	fusion	erreur	mode
Issa63	63	+3	claire	64,1	1,1	consensus
IMG_9008 $\dagger$	67	−16	médiane	69,4	2,4	consensus
BPM54	54	−56	foncée	51,0	3,0	sélection
BPM56	56	−65	très foncée	56,2	0,2	consensus
VideoTest4	58	−62	très foncée	62,4	4,4	consensus

Résultat : sur les 5 vidéos, la fusion adaptative reste **sous 5 bpm d’erreur** de l’ITA +3 à l’ITA −65 (4 cas sous 3 bpm, un à 4,4), en adaptant son mode à chaque vidéo. Le test à l’aveugle confirme l’absence de réglage *a posteriori*. *Deux réserves honnêtes* :

- Sur les carnations très foncées, les SNR sont souvent négatifs (signal ténu) — la justesse vient alors de l’**accord inter-méthodes** plus que du SNR, ce qui justifie d’utiliser *deux* indices de confiance (SNR *et* écart-type).
- Le cas le moins bon (VideoTest4, erreur 4,4) illustre une faiblesse de la médiane brute : deux méthodes (CHROM-ITA, POS) surestimaient *dans le même sens* (71 et 75 bpm), tirant la médiane à 62,4 alors que le vrai cluster bas — CNN 1D (57,1 ; erreur 0,9) et PhysNet (60,6) — était correct. Une médiane **pondérée par le SNR** ou un **rejet d’outlier** avant consensus corrigerait ce biais (piste §6).

Garde-fou vidéos 4K. Les vidéos haute résolution (p. ex. 2160×3840) saturent la mémoire si toutes les images sont chargées en pleine résolution. Le chargeur redimensionne désormais les images à `max_dim=720` dès la lecture (option `--max-dim` de `run_on_video.py`) — sans impact sur le signal rPPG, qui est temporel et non lié à la résolution spatiale.

4.6 Test *held-out* sur 22 sujets jamais vus (majorité Fitz 5–6)

Test le plus exigeant : 22 nouveaux sujets VitalVideos (54 scénarios), **jamais vus à l’entraînement**, à dominante de carnations foncées. Évaluation au niveau scénario.

TABLE 5 – Held-out, niveau scénario, **après correction du bug de modèles périmés** (tous les modèles appris ré-entraînés sur l’extraction propre). $\hat{z}$ Validés $\hat{z}$ = SNR > −1. La colonne $\hat{z}$ périmé $\hat{z}$ rappelle le score erroné avant correction.

Méthode	MAE	médiane	% < 5	Validés	MAE val.	(périmé)
PhysNet	3,89	0,00	83 %	35/52	0,25	3,89
CNN 1D	4,69	0,00	80 %	40/54	1,27	26,60
CHROM-ITA	8,27	0,00	67 %	21/54	4,27	11,82
CHROM	8,69	0,88	59 %	17/54	3,52	—
POS	9,90	0,88	65 %	23/54	3,90	—
Fusion adaptative	4,69	0,00	81 %	consensus	CE43, sél. CE11	15,30

(A) **Un bug de *modèle périmé*, pas un défaut d'architecture — correction d'une conclusion intermédiaire.** Une première lecture avait conclu que le CNN 1D n'aurait pas tenu (MAE 26,6, prédictions quasi-constantes, corrélation $-0,21$ avec la vraie FC) et qu'il fallait réduire sa capacité. **Le diagnostic réel est autre.** Les fichiers de poids du CNN 1D et de CHROM-ITA avaient été entraînés *le matin*, sur une extraction de **region_signals antérieure aux corrections de prétraitement** (double passe-bande sur les labels + fps mixtes), puis jamais ré-entraînés après la ré-extraction propre de midi. On évaluait donc des modèles appris sur des labels buggés. **Preuves** : (i) les dates des poids précèdent la ré-extraction ; (ii) ré-entraîner la *même* architecture sur les données propres redonne un modèle sain (CNN 1D : MAE **4,69**, corr 0,65 ; CHROM-ITA : $11,82 \rightarrow 8,27$) ; (iii) une étude d'ablation des canaux (207 / 69 / 21) montre que **réduire la capacité n'aide pas** — la version 207 canaux ré-entraînée propre est la meilleure — donc le problème n'était pas le sur-apprentissage. *Leçon de processus* : toujours ré-entraîner les modèles *après* une correction du prétraitement, et vérifier les horodatages poids vs données.

(B) **PhysNet domine en distribution, le CNN 1D suit de près.** Sur sujets VitalVideos non vus, PhysNet généralise remarquablement (MAE **3,89** ; $83\% < 5$ bpm ; 0,25 sur les validés) ; le CNN 1D ré-entraîné est juste derrière (4,69 ; 80 %). La **fusion adaptative** (4,69, désormais avec CNN 1D ré-inclus) égale le CNN 1D mais ne dépasse pas PhysNet seul : en distribution, ajouter de l'optique plus bruitée dilue la bonne estimation profonde.

(C) **Réconciliation avec les vidéos externes.** Contradiction apparente : sur les 2 vidéos smartphone (§4.4) PhysNet était *mauvais*, ici il est *excellent*. L'explication est le **décalage de domaine** : le held-out est au format VitalVideos (même distribution que l'entraînement : bon capteur, éclairage maîtrisé), tandis que les vidéos perso sont du smartphone H.264 (compression temporelle), distribution sur laquelle le prétraitement DiffNormalized de PhysNet se dégrade. *Leçon opérationnelle* :

- **En distribution** (vidéo type VitalVideos) : **faire confiance à PhysNet** (3,89 bpm), la fusion n'aide pas.
- **Hors distribution** (smartphone/compressé) : PhysNet n'est plus fiable ; les méthodes *sans modèle* (CHROM/POS) et la **fusion adaptative** deviennent le filet de sécurité.

La fusion adaptative garde donc toute sa valeur comme **robustesse au domaine inconnu**, mais ne doit pas masquer que, sur sa distribution, PhysNet est le meilleur estimateur isolé.

5 Discussion

Aucune méthode unique ne suffit. Chaque méthode a un régime de défaillance *différent* : POS est très précis quand il n'a pas le signal mais se tait souvent ; CNN 1D est le plus stable y compris sur peau foncée mais peut sur-apprendre ; PhysNet est honnête (bon SNR) mais conservateur ; CHROM-ITA est risqué. Cette **complémentarité** est précisément ce qui rend une fusion intéressante.

Le SNR est un bon proxy de confiance, mais pas une garantie. Il sépare bien succès et échecs *en moyenne*, mais le doublage d'harmonique (CHROM-ITA) montre qu'un signal peut être spectralement n'importe quel en pointant la mauvaise fréquence. D'où la nécessité de garde-fous physiologiques.

Honnêteté statistique. Les comparaisons entre sous-groupes Fitzpatrick doivent se faire à découpage de test *identique* : une n'importe quel MAE Fitz 6 = 15 bpm n'est qu'un unique sujet difficile n'est pas une preuve de biais systématique. Nous avons aussi vérifié l'**absence de fuite** entre train et test (GUID uniques) lorsqu'un résultat paraissait n'importe quel bon.

6 Pistes à explorer

1. **Fusion adaptative (ADOPTÉE, cf. §4.4).** Désormais méthode par défaut : *médiane* quand les méthodes s'accordent (faible écart-type), *sélection par SNR* quand elles divergent, avec garde anti-harmonique et sortie possible si mesure non fiable si tout échoue (logique Binah). À faire : (a) calibrer finement le seuil τ et le SNR de validation sur le test *held-out* ; (b) remplacer la médiane brute du mode consensus par une **médiane pondérée par le SNR** (ou un **rejet d'outlier** préalable), pour éviter qu'une paire de méthodes biaisées dans le même sens tire le consensus (cas VideoTest4, §4.5).
2. **Garde anti-harmonique.** Avant de valider une FC, vérifier qu'il n'existe pas un pic d'énergie comparable à FC/2 (sous-harmonique) dans la bande physiologique ; sinon corriger ou déclasser. Sécurise spécifiquement CHROM-ITA.
3. **Canal ballistocardiographique (BCG), indépendant de la couleur de peau.** Le BCG [11] mesure les *micro-mouvements* de la tête dus à l'éjection systolique (recul newtonien de l'afflux carotidien). Étant *mécanique*, il est **insensible à la mélanine** — exactement complémentaire de l'optique :

	rPPG optique	BCG (mouvement)
Source physique	couleur de peau	déplacement de la tête
Sensible à la mélanine	oui	non
Sensible au mouvement volontaire	moyen	fort
Sensible à l'éclairage	oui	non

Mise en uvre (non supervisée, réutilise nos landmarks) : suivre le déplacement vertical de points rigides (arête du nez, front) → ACP des trajectoires → composante la plus périodique dans $[0,7, 2,5]$ Hz → FFT → FC_{BCG} + son propre SNR, ajoutée comme votant supplémentaire à la fusion. *Condition* : tête immobile et caméra stable (assis/trépied) ; à proscrire en vidéo smartphone tenue à la main.

4. **Architecture de décision multi-signal type Binah.** Généraliser la politique SNR en un module de qualité appris (SQA) opérant par fenêtre, capable de combiner plusieurs constantes (FC, VFC, respiration) et de rejeter explicitement les segments douteux.
5. **Plus de données diversifiées.** La principale limite du CNN 1D (sur-apprentissage à 207 canaux) et du fine-tuning PhysNet est la taille du jeu. Poursuivre l'intégration de VitalVideos / d'un sous-ensemble africain (Fitz 5–6) pour densifier les carnations sous-représentées. Étudier aussi une **réduction du nombre de canaux** (moins de régions / d'espaces) pour réduire le sur-apprentissage du CNN 1D.
6. **Robustesse à la compression.** PhysNet (DiffNormalized) se dégrade sur vidéo H.264 fortement compressée ; explorer un prétraitement moins sensible aux artefacts temporels, ou un entraînement augmenté par compression simulée.

7 Conclusion

Le test *held-out* (§4.6) impose deux conclusions fortes. **(1) En distribution, les deux modèles appris dominant** : PhysNet fine-tuné (MAE **3,89** bpm, 83 % < 5 bpm) en tête, CNN 1D ré-entraîné juste derrière (4,69), sur des sujets VitalVideos jamais vus à dominante de peaux foncées — la fusion adaptative les égale mais ne dépasse pas PhysNet seul. **(2) Un incident de processus a été identifié et corrigé** : deux modèles (CNN 1D, CHROM-ITA) avaient été livrés entraînés sur une extraction *antérieure* aux corrections de prétraitement, faussant lourdement leur évaluation (CNN 1D : 26,6 au lieu de 4,7) ; tous les modèles ont été ré-entraînés sur données propres. La valeur propre de la **fusion adaptative** se situe *hors distribution* (vidéo

smartphone compressée, §4.4), où PhysNet décroche et où les méthodes sans modèle prennent le relais. Stratégie de déploiement recommandée : *PhysNet en primaire si le signal est de qualité (SNR élevé), fusion adaptative (CNN 1D/CHROM/POS $\pm$ futur BCG) en secours sinon*, avec rejet explicite quand toutes les méthodes échouent. La piste la plus prometteuse pour la robustesse inter-carnation reste l’ajout d’un canal **BCG**, physiquement indépendant de la mélanine, tout en restant *honnête* sur les cas impossibles.

Références

- [1] W. Verkruijsse, L. O. Svaasand, J. S. Nelson. *Remote plethysmographic imaging using ambient light*. Optics Express, 16(26) :21434–21445, 2008.
- [2] M.-Z. Poh, D. J. McDuff, R. W. Picard. *Non-contact, automated cardiac pulse measurements using video imaging and blind source separation*. Optics Express, 18(10) :10762–10774, 2010.
- [3] G. de Haan, V. Jeanne. *Robust pulse rate from chrominance-based rPPG*. IEEE Transactions on Biomedical Engineering, 60(10) :2878–2886, 2013. (CHROM)
- [4] W. Wang, A. C. den Brinker, S. Stuijk, G. de Haan. *Algorithmic principles of remote PPG*. IEEE Transactions on Biomedical Engineering, 64(7) :1479–1491, 2017. (POS)
- [5] Z. Yu, X. Li, G. Zhao. *Remote photoplethysmograph signal measurement from facial videos using spatio-temporal networks*. BMVC, 2019. (PhysNet)
- [6] W. Chen, D. McDuff. *DeepPhys : Video-based physiological measurement using convolutional attention networks*. ECCV, 2018.
- [7] X. Liu, J. Fromm, S. Patel, D. McDuff. *Multi-task temporal shift attention networks for on-device contactless vitals measurement (MTTS-CAN)*. NeurIPS, 2020.
- [8] X. Niu, H. Han, S. Shan, X. Chen. *RhythmNet : End-to-end heart rate estimation from face via spatial-temporal representation*. IEEE Transactions on Image Processing, 2019.
- [9] X. Niu, et al. *Video-based remote physiological measurement via cross-verified feature disentangling (MSTmap)*. ECCV, 2020.
- [10] C. Yu, J. Wang, C. Peng, C. Gao, G. Yu, N. Sang. *BiSeNet : Bilateral segmentation network for real-time semantic segmentation*. ECCV, 2018. (face parsing)
- [11] G. Balakrishnan, F. Durand, J. Guttag. *Detecting pulse from head motions in video*. CVPR, 2013. (BCG)
- [12] A. Chardon, I. Cretois, C. Hourseau. *Skin colour typology and suntanning pathways*. International Journal of Cosmetic Science, 13(4) :191–208, 1991. (ITA)
- [13] E. M. Nowara, D. McDuff, A. Veeraraghavan. *A meta-analysis of the impact of skin tone and gender on non-contact photoplethysmography measurements*. CVPR Workshops, 2020.
- [14] A. Dasari, S. K. A. Prakash, L. A. Jeni, C. S. Tucker. *Evaluation of biases in remote photoplethysmography methods*. npj Digital Medicine, 4 :91, 2021.
- [15] P. Toye. *VitalVideos : A dataset of face videos with PPG and blood pressure ground truth*. 2023. <https://vitalvideos.org>